

# Proyecto Semestral: Gestión de Datos Astronómicos

Profesor: Sebastián I. Alvarado Aceituno  
Mail: sebastian.alvarado2@mail.udp.cl

## 1. Contexto

El Observatorio Europeo Austral<sup>1</sup> (ESO) opera algunos de los telescopios más avanzados del mundo<sup>2</sup>. Instrumentos como el espectrógrafo X-shooter<sup>3</sup> equipado dentro del “*Very Large Telescope*”<sup>4</sup> ubicado en el Cerro Paranal (Antofagasta, Chile) generan diariamente terabytes de información. Un solo evento de observación no produce un único archivo, sino decenas de archivos agrupados que incluyen la observación científica principal (*Science Frames*) y múltiples archivos de calibración (*Bias*, *Flats*, *Arcs*).

Ustedes han sido contratados como el equipo de Ingeniería de Datos para diseñar la nueva arquitectura de almacenamiento y búsqueda. El objetivo principal es construir un motor de búsqueda que permita a los investigadores de todo el mundo consultar y encontrar rápidamente la ruta de almacenamiento de las imágenes científicas basándose en sus coordenadas espaciales (*Right Ascension* y *Declination*), su fecha de observación, el nombre de su objetivo, o cualquier otro atributo relevante.

### 1.1. Acerca de los Datos

Los archivos generados por los telescopios utilizan el formato binario estándar FITS, el cual contiene un extenso encabezado (*header*) con metadatos y el cuerpo principal con la imagen. Junto con este documento encontrarán una muestra real de estos metadatos extraídos, así como un dataset de muestra para que puedan realizar un análisis exploratorio.

Cuando se trabaja con bases de datos, debería<sup>5</sup> existir un archivo llamado “diccionario” el cual contiene todas las tablas, sus columnas, y el significado de cada una; para que los usuarios de la base de datos puedan realizar las consultas con facilidad. Con respecto a esto, la ESO también dispone de información para poder utilizar los datos que comparten, la cual se encuentra en el documento de este sitio: *ESO Data Interface Control Document*.

Teniendo el dataset de muestra y la información del header, ya tienen lo mínimo necesario para poder realizar un análisis exploratorio. Dado que se está trabajando con datos en formato FITS, se recomienda utilizar `python` con la librería `astropy`. Por ejemplo, para poder visualizar todos los campos del *header* pueden utilizar el siguiente código:

```
1 from astropy.io import fits
2
3 target_file = "./SHOOT.2008-11-14T07:09:03.690.fits"
4
5 with fits.open(target_file) as obs:
6     hdr = dict(obs[0].header)
7
8 for k,v in hdr.items():
9     print("%s : %s" % (k, str(v)))
```

Por otro lado, si quisieran descargar más datos, el código que generó el dataset compartido fue el siguiente:

```
1 from astroquery.eso import Eso
2
3 download_dir = "./raw_data"
4 max_files = 10
5 query = "xshooter"
6 eso = Eso() # Línea que conecta con el archivo científico de la ESO
7 query_result = eso.query_instrument(query, max_rows=max_files)
8 # Un registro de observación se compone de varios archivos,
9 # por lo que verán que van a obtener más de `max_files` archivos.
10 # El proceso termina descomprimiendo los archivos. Verifiquen que no falte alguno.
11 eso.retrieve_data(list(query_result["DP.ID"]), destination=download_dir)
```

<sup>1</sup><https://www.eso.org/public/chile/>.

<sup>2</sup>Y está construyendo el observatorio más grande del mundo en Chile! <https://elt.eso.org>.

<sup>3</sup><https://www.eso.org/public/teles-instr/paranal-observatory/vlt/vlt-instr/x-shooter/>.

<sup>4</sup><https://www.eso.org/public/chile/teles-instr/paranal-observatory/vlt/>.

<sup>5</sup>Por experiencia, les puedo comentar que muchas veces no se tiene a disposición el diccionario. Ya sea porque nunca existió, porque se perdió, porque la gente no sabe de su existencia, o porque la información que contiene es confidencial.

## 2. Requisitos Específicos de la Primera Entrega

### 2.1. Análisis Exploratorio

En general, cuando se lidia con un problema que involucre datos, lo primero que se sugiere hacer es un **análisis exploratorio**<sup>6</sup>. Este es un proceso para “analizar e investigar conjuntos de datos y resumir sus características principales, a menudo empleando métodos de visualización de datos”.

Para esta parte del proyecto lo que deben hacer es entregar características generales (estadísticas) para el conjunto de atributos o campos que componen el encabezado de los archivos fits que tendrán disponibles. Las estadísticas esperadas son:

1. Cantidad de campos por archivo.
2. Cantidad de campos sin información por archivo.
3. Varianza de los campos con información numérica.
4. Cantidad de elementos distintos por campo con información no numérica.
5. Cantidad de elementos con baja frecuencia (outliers) por campo con información no numérica.

Dado que la cantidad de campos en cada archivo es inmensa, lo recomendable sería buscar cuáles son las que son más relevantes. Entonces, en base a las estadísticas calculadas, mencionen qué campos podrían ser importantes de preservar en el modelo de datos, y por qué.

Como punto de partida, deberían considerar sí o sí los siguientes campos, los cuales son los que se mencionaron al comienzo del contexto (son los más usados para buscar).

**RA** Right Ascension

**DEC** Declination

**DATE-OBS** Fecha de observación

**OBJECT** Objeto astronómico objetivo

### 2.2. Definición de Tecnologías

Una vez entendido el problema a través de las estadísticas calculadas, se puede tomar una elección informada acerca de las tecnologías a utilizar para el proyecto.

Deben realizar una justificación detallada de las tecnologías a utilizar para almacenar los metadatos indexables y los archivos binarios pesados. Deben argumentar por qué un modelo puramente relacional (SQL) no es lo más adecuado para este volumen y variabilidad de datos.

La lista de tipos de tecnologías posibles son los vistos en clases:

- Bases de Datos Distribuidas orientadas a disco (ej. Hadoop).
- Bases de Datos Distribuidas orientadas a memoria (ej. Spark).
- Bases de Datos Documentales (ej. MongoDB).
- Bases de Datos orientadas a Grafos (ej. Neo4j).
- Bases de Datos orientadas a Columnas (ej. Cassandra).
- Bases de Datos de Clave-Valor (ej. Redis).

### 2.3. Definición del Modelo de Datos

Una vez definida la tecnología, el siguiente paso es definir el modelo de datos a implementar sobre la base de datos escogida.

El diseño del esquema a realizar debe soportar el motor de búsqueda que crearán. Deben especificar como se modelarán los campos de los encabezados de los documentos para permitir búsquedas rápidas y eficientes por coordenadas, fechas, o nombres; sin perder información relevante en el proceso.

Otra parte esencial del modelado de datos es la definición de restricciones o reglas que van a regir a los datos del modelo. En este caso deben proponer reglas de negocio para distinguir los archivos que serán indexados en el buscador de aquellos que serán descartados o movidos a un almacenamiento secundario.

Las reglas de negocio deberían surgir naturalmente del análisis exploratorio que realizaron, y de la información proveída en el contexto.

<sup>6</sup><https://www.ibm.com/mx-es/think/topics/exploratory-data-analysis>

### 3. Informe

Para el proyecto se solicita que en cada entrega se realice un informe tipo paper. Este tipo de informes se caracterizan por tener las siguientes secciones:

**Título** Título de informe, nombres de los integrantes junto con sus correos electrónicos.

**Resumen** Un párrafo que describe qué se hizo y qué resultados se obtuvieron.

**Introducción** Una sección en donde se incorpora el contexto de la realización del informe, se comenta brevemente cómo se realizó, su objetivo, y donde se detalla los contenidos de cada una de las secciones posteriores.

**Marco Teórico** Sección en donde se colocan todas las definiciones de los conceptos técnicos a utilizar en el resto del informe. Los contenidos de esta sección se deben justificar citando a la bibliografía.

**Desarrollo/Metodología** Sección donde se menciona y detalla todo lo que se hizo. Aquí no se emiten juicios ni se comenta acerca de los resultados.

**Análisis y Resultados** Sección en donde se mencionan los resultados que surgieron tras realizar la metodología de la sección anterior. Aquí también se coloca el análisis de los resultados y los descubrimientos que surgen de este proceso.

**Conclusión** Sección en donde se da un repaso breve de lo realizado y se verifica el cumplimiento de los objetivos y expectativas.

**Bibliografía** Sección en donde se citan las fuentes utilizadas para la confección del informe.

**Anexos** Sección opcional. Aquí se suelen colocar elementos relacionados al informe que no se incluyen en el cuerpo principal para no entorpecer la lectura. Por ejemplo, tablas muy grandes, códigos muy grandes, desarrollos muy largos.

Al igual que el presente documento, un informe tipo paper debe incluir un encabezado que aparezca en cada página. Los elementos típicos de un encabezado son:

- Logo de la institución.
- Nombre de la institución.
- Facultad o departamento de la asignatura.
- Carrera de la asignatura.
- Asignatura.
- Semestre.

#### 3.1. Rúbrica

Se evaluará cada sección según la descripción proveída. En caso de incorporar algún elemento en un sitio que no corresponde o en caso de que falte algún elemento, se descontará un porcentaje no mayor al 50 % del correspondiente a la sección.

En caso de omitir alguna sección por completo se descontará entre 5 y 20 décimas dependiendo de la relevancia de la sección.

En caso de cometer alguna falta de formato u ortografía, se descontarán décimas hasta un máximo de 10 décimas en total.

## 4. Presentación

La presentación debe ser un resumen ejecutivo del informe entregado, mostrando lo más importante en un tiempo de 5 minutos, y luego 3 minutos de preguntas del profesor.

Una buena presentación tiene los siguientes elementos a evaluar:

- Dominio de los contenidos.
- Organización de la información.
- Expresión oral.
- Lenguaje no verbal.
- Tiempo.
- Apoyo (diapositivas).
- Trabajo en equipo.

### 4.1. Rúbrica

Cada uno de los elementos a evaluar puede tener una calificación:

- Sobresaliente (4 puntos).
- Notable (3 puntos).
- Aprobado (2 puntos).
- Insuficiente (1 puntos).

## 5. Requisitos y Consideraciones Generales

- El proyecto se realiza de manera individual o en parejas.
- Cada entrega contará con un informe y una presentación breve.
- La nota del **informe es grupal**, y la de la **presentación es individual**.
- Cada entrega debe contener el archivo de la presentación y el archivo del informe en formato **pdf**.
- El día de cada presentación, el profesor tendrá descargadas todas las presentaciones en el computador de la universidad para ahorrar tiempo.
- El detalle de lo que se evalúa en un informe y en una presentación se detalla al final del documento.